

Reconnaissance de Figures avec un MLP

TP3 — INF372 : Apprentissage Automatique

TCHUENCHE KAMDEM Samuel Yedidya

MAYAGI PAUL Alain

NKOT JEAN Francky

Université de Yaoundé I
Département d'Informatique
Licence 3 Informatique

2024 – 2025

Plan de la présentation

- 1 Introduction et Objectifs
- 2 Dataset
- 3 Architecture du MLP
- 4 Entraînement
- 5 Résultats
- 6 Analyse des Activations
- 7 Conclusion

Contexte

La reconnaissance de chiffres manuscrits est un problème classique de vision par ordinateur et d'apprentissage automatique.

Objectifs du TP :

- Implémenter un **Perceptron Multicouche (MLP)** from scratch
- Utiliser la **Descente de Gradient Stochastique (SGD)**
- Analyser les **poids appris** via heatmaps
- Comprendre les **activations** de la couche cachée
- **Sortir de la boîte noire** du réseau de neurones

Dataset utilisé

MNIST — 70 000 images de chiffres manuscrits (0 à 9)

Description du Dataset

Caractéristiques des images :

- Taille : 32×32 pixels
- Format : niveaux de gris (PNG)
- Fond noir, chiffre blanc
- Normalisées entre 0 et 1
- Label dans le nom du fichier

Répartition :

Ensemble	Images	Classes
Train	60 000	0 – 9
Test	10 000	0 – 9
Total	70 000	10

Exemple de nomenclature

train_00000_label1_5.png
test_00001_label1_2.png

Distribution des classes

Le dataset est **équilibré** — chaque chiffre représente environ 10% des données.

- Train : $\approx 6\,000$ images/classe
- Test : $\approx 1\,000$ images/classe

Architecture du MLP

Table – Couches du réseau


Couche	Taille	Activation
Entrée	1024 (32×32)	–
Cachée	64 neurones	ReLU
Sortie	10 neurones	Softmax

Fonctions d'activation :

- **ReLU** : $f(x) = \max(0, x)$
- **Softmax** : probabilité par classe

Nombre de paramètres :

- $1024 \times 64 + 64 = 65\,600$



Descente de Gradient Stochastique

Au lieu de calculer le gradient sur tout le dataset, la SGD met à jour les poids après chaque **mini-batch**.

Paramètres utilisés :

Paramètre	Valeur
Solver	SGD
Learning rate	0.01
Epochs	100
Batch size	32
Activation	ReLU

Principe de la SGD :

- 1 Prendre un mini-batch de 32 images
- 2 Calculer la perte (loss)
- 3 Calculer le gradient par **rétropropagation**
- 4 Mettre à jour les poids : $w \leftarrow w - \eta \nabla L$
- 5 Répéter jusqu'à convergence

Convergence

1 epoch = le modèle voit les **60 000 images** une fois, soit **1 875 mises à jour** des poids.

Performances finales

Métrique	Valeur
Accuracy Train	98.80%
Accuracy Test	93.25%
Ecart	$\approx 5.5\%$

Interprétation :

- La loss diminue régulièrement
- L'accuracy train et test convergent
- L'écart de 5.5% indique une **légère overfitting**, normale pour un MLP simple
- Le modèle **généralise bien** sur des





Figure – Courbes de loss et d'accuracy

Analyse des Poids — Heatmaps

Heatmap des poids — Couche cachée (64 neurones)

Rouge = poids positif (le pixel excite le neurone) | Bleu = poids négatif (le pixel inhibe le neurone) | Blanc = poids nul (le pixel n'influence pas le neurone)



Lecture de la heatmap :

- **Rouge** : poids positif — le pixel **excite** le neurone
- **Blanc** : poids nul — le pixel est **ignoré**
- **Bleu** : poids négatif — le pixel **inhibe** le neurone

Observations :

- Les zones blanches augmentent avec les epochs — le réseau **ignore** les pixels **inutiles**

Analyse des Activations par Classe

Ce que montrent les activations :

- Chaque chiffre active un **profil de neurones différent**
- Les chiffres simples (1) activent **peu de neurones**
- Les chiffres complexes (8) activent **davantage de neurones**
- Les classes similaires (1/7, 3/8) partagent des neurones actifs communs

Activations moyennes de la couche cachée (8x8) par classe




Figure – Activations moyennes par classe (8x8)

Fausse prédictions

Lors d'une erreur, le profil d'activation ressemble davantage à la **classe prédite** qu'à la vraie classe — le réseau ne se trompe pas au hasard

Analyse des neurones :

- Les neurones quasi-blancs (N41, N46) sont **peu specialises** — ils contribuent peu a la decision finale
- Les neurones avec des zones colorees detectent des **regions precises** de l'image
- Les classes similaires (1/7, 3/8, 4/9) **partagent des neurones actifs**, ce qui explique les confusions
- Lors d'une erreur, le profil d'activation ressemble davantage a la **classe predite** qu'a la vraie classe
- Les zones blanches augmentent avec les epochs — le reseau **ignore progressivement les pixels inutiles**

Conclusion :

- Accuracy test de **93.25%** avec un MLP simple
- La SGD converge en **100 epochs** de maniere stable
- L'analyse des poids et activations permet de **sortir de la boite noire** du reseau
- Le MLP ignore la structure **spatiale** des images — limite inherente a l'architecture
- L'ecart train/test de 5.5% indique une **legere overfitting**, normale pour un MLP simple

Le MLP atteint **93.25%** de precision et son analyse interne confirme que le reseau apprend des representations pertinentes des chiffres manuscrits.

Merci pour votre attention

Questions ?

TCHUENCHE KAMDEM Samuel Yedidya
MAYAGI PAUL Alain
NKOT JEAN Francky

Université de Yaoundé I — Département d'Informatique — L3